Ce que contient un fichier

Mardi 20 octobre, après-midi · 2 h 30 · à faire en binôme, cahier ouvert

> Le geste de cette semaine, c'est regarder un fichier colonne par colonne et se demander ce qu'il contient réellement. Cet après-midi, on le fait sur un fichier qui contient des personnes.
>
> Aucun cours de droit. Six questions, deux fichiers, et vous tranchez.

Les deux fichiers

Vous avez travaillé sur deux jeux de données depuis le début de la formation. Mettez-les côte à côte.

La table `clients` d'UrbanStay — exécutez ceci dans DBeaver :

```
SELECT * FROM clients LIMIT 5;
```

Quatre colonnes : `client_id`, `pays`, `segment_client`, `date_inscription`.

Le fichier `dim_client.csv` de NovaTel — celui du brief de Mohamed. Ouvrez-le dans un tableur.

Onze colonnes : `client_id`, `prenom`, `nom`, `email`, `sexe`, `date_naissance`, `tranche_age`, `ville`, `region`, `segment_client`, `date_entree_client`. **10 150 lignes.**

Question 1 — Qui est reconnaissable ? · 15 min

Pour chacun des deux fichiers, répondez par écrit :

> **Si ce fichier était perdu dans la rue, est-ce que quelqu'un pourrait savoir de qui il parle ?**

Puis, dans le fichier NovaTel, **dressez la liste des colonnes qui permettent de le savoir.** Il y en a plus qu'il n'y paraît : une colonne qui ne nomme personne peut, combinée à deux autres, ne laisser qu'une seule personne possible.

> Gardez votre liste. On y revient à la question 5.

Question 2 — Combien de personnes ? · 20 min

Le fichier NovaTel compte 10 150 lignes. **Combien de personnes ?**

La question n'est pas rhétorique, et vous avez les moyens d'y répondre. Comptez deux choses : **le nombre de lignes**, et le nombre de **valeurs distinctes** dans la colonne `email`.

Deux chemins, prenez celui que vous préférez.

Dans le tableur — sur la colonne `email` : `Données ▸ Supprimer les doublons` sur une **copie** de la colonne, et comparez le nombre de lignes avant et après.

En Python — les trois lignes sont ici, recopiez-les telles quelles :

```
import pandas as pd
clients = pd.read_csv("dim_client.csv")
print(len(clients), clients["email"].nunique())
```

Vous allez trouver deux nombres très différents. Cherchez ensuite l'adresse qui revient le plus souvent — `print(clients["email"].value_counts().head(3))` — et regardez les lignes concernées.

> **La question, et prenez-la au sérieux :** si une personne apparaît sous plusieurs `client_id`, que vaut la phrase « nous avons 10 150 clients » ? Et si cette personne demande demain la suppression de ses données, combien de lignes faut-il supprimer — et comment les retrouveriez-vous ?

Question 3 — À quoi sert chaque colonne ? · 20 min

Prenez les onze colonnes de `dim_client.csv`. Pour chacune, une ligne dans votre cahier :

Colonne	À quoi elle sert dans une analyse de ventes	Peut-on s'en passer ?

Faites-le vraiment colonne par colonne, sans en sauter une. Puis répondez :

> **Combien de colonnes avez-vous réussi à marquer « on peut s'en passer » ?**

Deux cas méritent un arrêt.

`prenom` et `nom`. Qu'est-ce qu'un prénom apporte à une analyse de chiffre d'affaires par région ? Et si ce n'est rien, pourquoi sont-ils là ?

`sexe`. Comptez ses valeurs — il y en a trois, dont une qui n'est ni F ni M, sur 29 lignes. Que feriez-vous de ces 29 lignes dans une analyse par genre, et surtout : **qui a décidé que cette colonne devait exister ?**

Question 4 — Deux colonnes pour la même chose · 20 min

`date_naissance` et `tranche_age` disent la même chose, l'une précisément, l'autre par paquets.

Vérifiez-le. Prenez trois lignes au hasard, calculez l'âge à partir de la date de naissance, et comparez à la tranche.

Un détail : la tranche n'a pas été calculée aujourd'hui, mais **au 1er janvier 2025**. Depuis, certaines personnes ont changé de tranche sans que le fichier le sache. Sur les 10 150 lignes, **1 648 tranches sont aujourd'hui fausses** — et rien dans le fichier ne le signale.

Deux questions, et elles ne vont pas dans le même sens :

> **a.** Si l'analyse n'a besoin que de la tranche d'âge, pourquoi garder la date de naissance exacte ?
>
> **b.** Si on ne garde que la tranche, on garde une information qui vieillit mal. Comment réglez-vous ça ?

> Il n'y a pas une bonne réponse. Il y a une réponse qu'on assume, et qu'on écrit quelque part.

Question 5 — Le fichier que vous auriez construit · 15 min

Reprenez la liste de la question 1 et le tableau de la question 3.

Écrivez les colonnes du fichier que vous auriez demandé au prestataire, pour répondre à la même question d'analyse — le chiffre d'affaires par région, par segment et par tranche d'âge.

Comparez ensuite avec la table `clients` d'UrbanStay, qui ne contient ni nom, ni e-mail, ni date de naissance, et qui a pourtant permis toutes vos analyses depuis cinq semaines.

> **La question :** qu'est-ce que vous n'avez pas pu faire, depuis cinq semaines, faute de connaître le nom des clients d'UrbanStay ?

Question 6 — Et si ce fichier fuitait ? · 10 min

Cinq lignes dans votre cahier.

> **Le fichier NovaTel se retrouve en ligne. Qu'est-ce qui arrive aux 10 150 personnes ?**
>
> Puis la même question pour la table `clients` d'UrbanStay.

Mise en commun — 15 min

Chaque binôme donne **un seul point** : la colonne dont il s'est le plus facilement passé, et celle dont il n'a pas réussi à se passer.

C'est là qu'on nomme les choses. Six mots, et vous avez déjà travaillé les six :

Le mot	Ce que vous venez de faire
Donnée personnelle	la liste de la question 1 : toute information qui permet de reconnaître une personne, directement ou en la combinant avec une autre
Donnée sensible	la colonne `sexe` — une catégorie dont la loi encadre spécialement l'usage, parce qu'elle permet de discriminer
Finalité	la colonne de droite de votre tableau : à quoi ça sert. Sans finalité écrite, une colonne n'a pas de raison d'être là
Minimisation	la question 5 : on ne collecte que ce dont on a besoin pour la finalité annoncée. Pas ce qui pourrait servir un jour
Durée de conservation	la question 4b : une donnée a une date de péremption, et elle doit être écrite avant la collecte
Pseudonymisation ≠ anonymisation	remplacer le nom par `CLI00001` ne protège personne si `email` reste dans la colonne d'à côté. Anonymiser, c'est rendre la personne **non retrouvable**, y compris en recoupant

Le mot de la fin, et il est pour vous. Dans six mois, en entreprise, personne ne vous demandera votre avis sur le RGPD. On vous enverra un fichier, et vous serez la seule personne de la pièce à l'avoir ouvert colonne par colonne. **C'est à ce moment-là que ça se joue.**

Ce que vous rendez

Avec les livrables du mardi :

1. Votre tableau des onze colonnes (question 3).
2. Les deux nombres de la question 2, et votre réponse sur la suppression.
3. La liste des colonnes du fichier que vous auriez demandé (question 5).
4. Vos cinq lignes de la question 6.

> **Ces données sont fictives.** Les prénoms, les noms et les adresses du fichier NovaTel ont été fabriqués pour la formation — c’est d’ailleurs visible si vous comptez les combinaisons prénom + nom. Rien de ce que vous faites cet après-midi ne concerne une personne réelle. Mais tout ce que vous y apprenez concernera de vraies personnes dans six mois.